

LLM-Modellvergleich: Structured Output für VBuddy-Agents

Vergleich von vier selfhosted Ollama-Modellen als Planning-Agent-Backbone für die VBuddy-Anwendung. Getestet mit 21 LLM-Integrationstests, die den tatsächlichen Output der AI Services auf Struktur, Format, Plausibilität und inhaltliche Qualität prüfen.

Testumgebung:

- Ollama auf `192.168.0.251:11434`
- LangChain4j 0.36.2 mit `AiServices.builder()` (Structured Output via JSON-Schema)
- Kein Spring Context, keine DB — reine LLM-zu-Interface-Tests
- Jedes Modell wurde als Planning-/Schedule-/ChatAnalysis-Modell getestet, während `qwen3:8b` durchgehend als Execution-/Enrichment-Modell diente

Getestete Modelle

Modell	Parameter	Größe	Quantisierung	Familie
<code>deepseek-r1:7b</code>	7.6B	4.7 GB	Q4_K_M	qwen2
<code>qwen3:8b</code>	8.2B	5.2 GB	Q4_K_M	qwen3
<code>deepseek-r1:14b</code>	14.8B	9.0 GB	Q4_K_M	qwen2
<code>qwen3:14b</code>	14.8B	9.0 GB	Q4_K_M	qwen3

Gesamtergebnis

Modell	Bestanden	Fehler	Failures	Gesamt	Quote
<code>qwen3:14b</code>	21	0	0	21	100%
<code>deepseek-r1:14b</code>	19	1	1	21	90%
<code>deepseek-r1:7b</code>	17	4	0	21	81%
<code>qwen3:8b</code>	16	5	0	21	76%

Detailergebnisse pro Test

BackgroundEnrichmentAiService (Execution-Modell: `qwen3:8b`)

Generiert einen Erzähltext in 3. Person aus strukturierten Charakterdaten.

Test	deepseek-r1:7b	qwen3:8b	deepseek-r1:14b	qwen3:14b
enrichBackground_returnsNarrativeText	PASS	PASS	PASS	PASS
enrichBackground_isWrittenInThirdPerson	PASS	PASS	PASS	PASS

Alle Modelle nutzen hier qwen3:8b als Execution-Modell — keine Unterschiede. Output-Qualität durchgehend gut: lebendige Erzähltexte, korrekte 3. Person, 500+ Zeichen.

BackgroundPlanningAiService (Planning-Modell)

Generiert ein strukturiertes Charakterprofil (PlannedBackground-Record mit 13 Feldern).

Test	deepseek-r1:7b	qwen3:8b	deepseek-r1:14b	qwen3:14b
planBackground_returnsCompleteCharacterProfile	PASS	PASS	PASS	PASS
planBackground_ageIsConsistentWithPersonality	ERROR (MalformedJson)	PASS	PASS	PASS

Inhaltliche Qualität im Vergleich:

Aspekt	deepseek-r1:7b	qwen3:8b	deepseek-r1:14b	qwen3:14b
Alter erkannt (28)	Ja	Ja	Ja	Ja
Aussehen	"Mittelaltiggro ß" (Encoding-Artefakte)	"Mittelgroß, schlank, karamellbraune Kurzhaare"	"1,85 m groß, sportliche Figur, kurze Stoppeln"	"Mittelgroß, dunkle kurze Haare, schmale Brille, sportlich"
Hobbys	"Gärtnern, Wandern, Kochen" (OK)	"Erkundet neue Restaurants, Bridge" (kreativ)	"Hiking, Klettern, Spieleentwurf" (vielfältig)	"Laufen, Mountainbiken, Kochen exotischer Gerichte, Food-Festivals"
Macken	"Trinkt Kaffee aus spezieller Tasse"	"Stolpert über eigene Füße, zählt Bäume"	"Fummelt am Rucksack, spezielle Kaffeemischung"	"Bestimmte Messerschleife, redet bei Stress leise und schnell"
Kohärenz	Teils wirr ("JungenInterpolator", "Tochter" bei 28j. Single)	Gut kohärent	Gut, aber teils Sprachwechsel ins Englische	Sehr gut — durchgehend kohärent und auf Deutsch
Reasoning	Teils unverständlich	Klar und nachvollziehbar	Ausführlich und kausal verknüpft	Exzellent — erklärt jede Entscheidung mit Bezug zur Persönlichkeit

Fazit: qwen3:14b liefert die kohärentesten und detailliertesten Profile — durchgehend auf Deutsch, mit nachvollziehbarem Reasoning. qwen3:8b ist ebenfalls gut. deepseek-r1:14b wechselt gelegentlich ins Englische. deepseek-r1:7b produziert teils unsinnige Inhalte.

ChatPlanAnalysisAiService (Planning-Modell)

Analysiert Chatverläufe auf vereinbarte Planänderungen (CANCEL, UPDATE, ADD).

Test	deepseek-r1:7b	qwen3:8b	deepseek-r1:14b	qwen3:14b
smalltalk_noAdjustment	PASS	PASS	PASS	PASS
cancelRequest_detectsAdjustment	ERROR (NumberFormat "1L")	PASS	PASS	PASS
addRequest_detectsNewTask	FAIL (false negative)	PASS	PASS	PASS

Detailanalyse der Ergebnisse:

Smalltalk (alle bestanden):

Modell	Reasoning
deepseek-r1:7b	Korrekt erkannt, aber Reasoning teils unklar
qwen3:8b	"Konversation besteht aus Smalltalk und positiven Rückfragen"
deepseek-r1:14b	"Der Nutzer hat keine explizite Änderung vorgeschlagen. Die Gespräche bestehen aus Smalltalk."
qwen3:14b	"Der Nutzer fragt nur nach dem Wohlbefinden und wünscht viel Spaß beim bestehenden Joggen. Es gibt keine explizite Vorschläge zur Änderung des Tagesplans."

Cancel-Request:

Modell	Ergebnis	Detail
deepseek-r1:7b	ERROR	LLM gab "1L" statt 1 als existingTaskId zurück (Java-Long-Literal im JSON)
qwen3:8b	PASS	`CANCEL
deepseek-r1:14b	PASS	`CANCEL
qwen3:14b	PASS	`CANCEL

Add-Request:

Modell	Ergebnis	Detail
deepseek-r1:7b	FAIL	adjustmentNeeded: false — hat die Zustimmung nicht erkannt
qwen3:8b	PASS	`ADD
deepseek-r1:14b	PASS	`ADD
qwen3:14b	PASS	`ADD

Fazit: qwen3:14b zeigt das beste Reasoning — prüft sogar Kollisionsfreiheit mit bestehenden Tasks. deepseek-r1:14b generiert den kreativsten Titel. deepseek-r1:7b scheitert an JSON-Formatierung und inhaltlicher Erkennung.

EnrichmentAiService (Execution-Modell: qwen3:8b)

Reichert kurze Task-Beschreibungen mit Details an.

Test	deepseek-r1:7b	qwen3:8b	deepseek-r1:14b	qwen3:14b
enrichTask_returnsDetailedDescription	PASS	PASS	PASS	PASS
enrichTask_isWrittenInGerman	PASS	PASS	PASS	PASS

Alle nutzen qwen3:8b — keine Unterschiede. Output durchgehend gut.

ExecutionAiService (Execution-Modell: qwen3:8b für 7b/8b, deepseek-r1:14b für 14b-Run)

Generiert Blogartikel und Bedürfnis-Anpassungen.

Test	deepseek-r1:7b	qwen3:8b	deepseek-r1:14b	qwen3:14b
executeTask_returnsValidBlogAndNeedAdjustments	PASS	PASS	PASS	PASS
executeTask_needAdjustmentsAreValid	PASS	PASS	ERROR (JSON)	PASS
executeTask_cookingReducesHunger	PASS	PASS	PASS	PASS
executeTask_blogIsWrittenInFirstPerson	PASS	PASS	PASS	PASS

Hinweis: Beim 14b-Run wurde qwen3:8b weiterhin als Execution-Modell verwendet. Der eine JSON-Fehler ist sporadisch und nicht modellspezifisch — LangChain4j konnte die LLM-Antwort nicht parsen. Bei Wiederholung würde der Test wahrscheinlich bestehen.

Fazit: qwen3:8b ist als Execution-Modell sehr zuverlässig (11/12 Testläufe bestanden).

PlanningAiService (Planning-Modell)

Komplexester Agent: 9 Eingabeparameter, generiert 3-5 Tasks mit Zeitstempeln, Orten und Dauern.

Test	deepseek-r1:7b	qwen3:8b	deepseek-r1:14b	qwen3:14b
planTasks_returnsValidStructuredOutput	ERROR (Array statt Object)	ERROR (MalformedJson)	PASS	PASS
planTasks_tasksAreChronological	ERROR (DateTime "T"-Format)	PASS	PASS	PASS
planTasks_highHunger_includesFoodRelatedActivity	PASS	ERROR (String statt Object)	PASS	PASS

Output-Vergleich der 14b-Modelle (beide 3/3):

deepseek-r1:14b:

```
Reasoning: The activities were chosen based on Max's high exercise need
and moderate hunger.

2026-03-21 17:00 | Sport Session      | Zu Hause      | 60 min
2026-03-21 18:00 | Dinner at Home | Zu Hause      | 60 min
2026-03-21 19:00 | Evening Walk   | Nachbarschaft | 60 min
2026-03-21 20:00 | Relaxation Time | Zu Hause      | 120 min
```

- 4 Tasks, englische Titel, Reasoning auf Englisch
- Korrektes Format, valides JSON

qwen3:14b:

```
Reasoning: Max ist während der Arbeitszeit (13:00-17:00) am Arbeiten,
gefolgt von Sport (17:00-18:00), um seinen hohen Bedarf an
Bewegung zu stillen. Danach genießt er ein Abendessen
(18:00-19:00), um den Hunger zu stillen.

2026-03-21 15:14 | Arbeit        | Zu Hause      | 106 min
2026-03-21 17:00 | Sport (Laufen) | Nürnberger Park | 60 min
2026-03-21 18:00 | Abendessen     | Zu Hause      | 60 min
```

- 3 Tasks, deutsche Titel, Reasoning auf Deutsch mit Begründung pro Bedürfnis
- Bezieht sich explizit auf den Wochenplan (Arbeitszeit 13:00-17:00)
- Korrektes Format, valides JSON

Fehlerarten der kleineren Modelle:

Fehler	deepseek-r1:7b	qwen3:8b
Expected BEGIN_OBJECT but was BEGIN_ARRAY	Ja	—
Expected BEGIN_OBJECT but was STRING	—	Ja (2x)
MalformedJsonException: Expected ':'	—	Ja
DateTimeParseException (T statt Leerzeichen)	Ja	—
Timeout (>300s)	Ja (371s)	—

Fazit: Der PlanningAiService-Prompt ist der Hrtetest. Nur die 14b-Modelle produzieren zuverlssig valides JSON bei 9 Eingabeparametern. qwen3:14b hat den Vorteil, durchgehend auf Deutsch zu antworten und den Wochenplan-Kontext aktiv zu nutzen.

SchedulePlanningAiService (Planning-Modell)

Erstellt einen 24h-Wochenplan mit lckenlosen Zeitblcken.

Test	deepseek-r1:7b	qwen3:8b	deepseek-r1:14b	qwen3:14b
planSchedule_returnsWeekdayAndWeekendBlocks	PASS	PASS	PASS	PASS
planSchedule_timeBlocksHaveValidFormat	PASS	ERROR (JSON)	PASS	PASS
planSchedule_coversFullDay	PASS	ERROR (null weekday)	PASS	PASS
planSchedule_blocksAreContiguous	PASS	ERROR (JSON)	FAIL (Lcke 08:30→09:00)	PASS

Generierter Stundenplan im Vergleich:

deepseek-r1:7b (4/4, aber inhaltlich fragwrdig):

```
00:00-08:00 Liebe Nacht
08:00-08:30 Mornings pause (Kaffee trinken)
08:30-16:30 Arbeit im Bro
16:30-16:45 Pausen (Kurzes Bagnus)
16:45-24:00 Arbeit          ← 7:15h Arbeit am Abend?
```

qwen3:8b (1/4 — JSON-Parsing scheitert bei dieser Struktur):

- 3 von 4 Tests scheitern an ungltigem JSON
- Wenn JSON parst: Inhalte wren wahrscheinlich gut

qwen3:14b (4/4 — einziges Modell mit perfekter Score):

Wochentag:

00:00-07:00 Schlafen
07:00-07:30 Morgenroutine (Duschen, Kaffee)
07:30-08:00 Frühstück
08:00-09:00 Pendeln mit dem Fahrrad
09:00-12:00 Arbeit im Büro (Backend-Entwicklung)
12:00-13:00 Mittagspause (Imbiss, kurze Wanderung)
13:00-14:00 Kurze Pause (Kaffee, Nachrichten)
14:00-17:00 Arbeit im Büro (Code-Reviews, Bug-Fixing)
17:00-18:00 Pendeln mit dem Fahrrad
18:00-19:30 Kochabend (aufwendige Gerichte)
19:30-21:00 Science-Fiction-Romane Lesen
21:00-23:00 Leisure (Spiele, Online-Communities)
23:00-00:00 Schlafen

Wochenende:

00:00-08:00 Schlafen
08:00-08:30 Morgenroutine (Duschen, Kaffee)
08:30-09:30 Frühstück
09:30-11:00 Joggen im Park
11:00-14:00 Freizeit (Bücher, Online-Kurse)
14:00-17:00 Klettern mit Freunden (Gym/Outdoor)
17:00-19:00 Essen mit Freunden (Restaurant)
19:00-21:00 Kochabend (experimentelle Gerichte)
21:00-23:00 Science-Fiction-Romane Lesen
23:00-00:00 Schlafen

- 13 Wochentag-Blöcke, 10 Wochenend-Blöcke — detailliert und lückenlos
- Vollständige 24h-Abdeckung (00:00-00:00), alle Blöcke nahtlos aneinander
- Beruf korrekt als Backend-Entwicklung mit konkreten Aufgaben (Code-Reviews, Bug-Fixing)
- Pendeln mit dem Fahrrad — kreatives Detail passend zur sportlichen Persönlichkeit
- Wochenende: Klettern mit Freunden, Restaurant — soziale Aktivitäten trotz Introversion
- Durchgehend auf Deutsch

deepseek-r1:14b (3/4, inhaltlich exzellent):

Wochentag:

00:00-07:00 Schlafen
07:00-07:15 Aufwachen, Duschen
07:15-07:30 Frühstück
07:30-08:00 Berufsmails checken
08:00-10:00 Arbeit
10:00-10:15 Kaffeepause
10:15-12:00 Arbeit
12:00-13:00 Mittagessen
13:00-15:00 Arbeit
15:00-15:15 Kaffeepause
15:15-17:00 Arbeit
17:00-17:15 Heimweg
17:15-17:30 Entspannung
17:30-19:00 Sport (Jogging)
19:00-19:30 Duschbad
19:30-20:00 Abendessen vorbereiten
20:00-20:30 Abendessen
20:30-21:30 Science-Fiction-Roman lesen
21:30-23:00 Entspannung
23:00-00:00 Schlafen

Wochenende:

00:00-09:00 Schlafen
09:00-09:15 Aufwachen, Duschen
09:15-09:30 Frühstück
09:30-11:00 Jogging/Ausflug
11:00-11:30 Heimkommen, entspannen
11:30-12:30 Mittagessen
12:30-14:00 Entspannung, lesen
14:00-15:00 Spaziergang
15:00-16:00 Kochen vorbereiten
16:00-17:30 Relaxation oder lesen
17:30-18:30 Abendessen
18:30-20:00 Film schauen oder lesen
20:00-21:00 Entspannung
21:00-00:00 Schlafen

- 20 Wochentag-Blöcke, 14 Wochenend-Blöcke — extrem detailliert
- Vollständige 24h-Abdeckung (00:00-00:00)
- Realistische Zeiten (8h Arbeit, Kaffeepausen, Pendeln)
- Persönlichkeitsgetreu (Jogging, Science-Fiction, Kochen)
- Einziger Fehler: Bei einem separaten Testlauf entstand eine Lücke (08:30→09:00)

Fazit: qwen3:14b ist das einzige Modell mit 4/4 — lückenloser Stundenplan, durchgehend auf Deutsch, mit kreativen Details (Fahrrad-Pendeln, Klettern mit Freunden). deepseek-r1:14b ist ebenfalls gut (3/4), produziert aber gelegentlich Lücken. deepseek-r1:7b produziert valides JSON, aber unsinnige Inhalte. qwen3:8b scheitert meist am JSON-Parsing für diese komplexe verschachtelte Struktur.

ScheduleEnrichmentAiService (Execution-Modell: qwen3:8b)

Verbessert Formulierungen im Stundenplan, behält Zeiten und Blockanzahl bei.

Test	deepseek-r1:7b	qwen3:8b	deepseek-r1:14b	qwen3:14b
enrichSchedule_preservesTimesAndBlockCount	PASS	PASS	PASS	PASS

Alle nutzen qwen3:8b — durchgehend zuverlässig.

Durchlaufzeiten

Gesamtlaufzeit

Modell	Gesamtdauer	Durchschnitt pro Test
deepseek-r1:7b	8:50 min	25.2s
qwen3:14b	15:03 min	43.0s
qwen3:8b	16:07 min	46.0s
deepseek-r1:14b	16:39 min	47.6s

Hinweis: Die Gesamtdauer von deepseek-r1:7b ist trügerisch niedrig — ein Test endete nach 371s mit Timeout (zählt als Error, nicht als vollständiger Durchlauf), und mehrere Tests brachen schnell mit JSON-Parsing-Fehlern ab, bevor der LLM überhaupt antworten konnte. Die effektive Laufzeit bei erfolgreichen Tests ist vergleichbar.

Laufzeiten pro Testklasse

Testklasse (Anzahl Tests)	deepseek-r1:7b	qwen3:8b	deepseek-r1:14b	qwen3:14b
BackgroundEnrichment (2)	33.3s	30.9s	29.9s	31.3s
BackgroundPlanning (2)	~43s*	58.5s	100.6s	100.2s
ChatPlanAnalysis (3)	22.8s	48.8s	45.9s	43.8s
Enrichment (2)	~19s	20.3s	19.7s	17.9s
Execution (4)	~168s	134.6s	205.2s	122.5s
PlanningAiService (3)	~430s (inkl. Timeout)	225.4s	206.5s	276.4s
ScheduleEnrichment (1)	30.8s	50.1s	41.5s	37.9s
SchedulePlanning (4)	126.3s	395.3s	348.2s	271.2s

* Geschätzt — einzelne Testzeiten nicht vollständig im Log sichtbar.

Durchschnittliche Antwortzeit pro LLM-Aufruf (geschätzt)

Berechnet aus den Testklassen, die das jeweilige Modell als Planning-Modell nutzen (BackgroundPlanning, ChatPlanAnalysis, PlanningAiService, SchedulePlanning):

Modell	Ø pro Aufruf	Schnellster	Langsamster
deepseek-r1:7b	~52s	~8s (ChatAnalysis)	371s (Planning, Timeout)
qwen3:8b	~61s	~16s (ChatAnalysis)	~120s (SchedulePlanning)
deepseek-r1:14b	~58s	~15s (ChatAnalysis)	~100s (SchedulePlanning)
qwen3:14b	~58s	~15s (ChatAnalysis)	~92s (PlanningAiService)

Laufzeit vs. Erfolgsrate

Modell	Gesamtzeit	Erfolgreiche Tests	Zeit pro erfolgreichem Test
deepseek-r1:7b	8:50 min	17	31.2s
qwen3:14b	15:03 min	21	43.0s
qwen3:8b	16:07 min	16	60.4s
deepseek-r1:14b	16:39 min	19	52.6s

qwen3:14b hat die beste Effizienz: 100% Erfolgsrate bei der zweitschnellsten Gesamtzeit. deepseek-r1:7b ist zwar am schnellsten, liefert aber die meisten fehlgeschlagenen Aufrufe — und jeder fehlgeschlagene Aufruf kostet im Produktivbetrieb einen Retry.

Antwortzeiten nach Prompt-Komplexität

Komplexität	Beschreibung	deepseek-r1:7b	qwen3:8b	deepseek-r1:14b	qwen3:14b
Einfach (1-2 Params)	BackgroundPlanning, Enrichment	~20s	~25s	~40s	~40s
Mittel (3-5 Params)	ChatPlanAnalysis, SchedulePlanning	~30s	~60s	~55s	~50s
Komplex (9 Params)	PlanningAiService	Timeout/Error	Error	~70s	~92s

Bei einfachen Prompts ist deepseek-r1:7b am schnellsten. Bei komplexen Prompts scheitern die 7b/8b-Modelle oft ganz, während beide 14b-Modelle zuverlässig antworten. qwen3:14b braucht beim komplexesten Prompt etwas länger als deepseek-r1:14b (~92s vs. ~70s), liefert dafür aber 100% valides JSON und durchgehend deutsche Inhalte.

Fehlerklassifikation

JSON-Parsing-Fehler (LangChain4j kann LLM-Output nicht parsen)

Fehlertyp	deepseek-r1:7b	qwen3:8b	deepseek-r1:14b	qwen3:14b
Expected BEGIN_OBJECT but was STRING	—	3x	1x	—
Expected BEGIN_OBJECT but was BEGIN_ARRAY	1x	—	—	—
MalformedJsonException (kaputte Syntax)	1x	1x	—	—
NumberFormatException ("1L" statt 1)	1x	—	—	—
Gesamt JSON-Fehler	3	4	1	0

Inhaltliche Fehler (valides JSON, aber falscher Inhalt)

Fehlertyp	deepseek-r1:7b	qwen3:8b	deepseek-r1:14b	qwen3:14b
Lücke im Stundenplan	—	—	1x	—
Add-Request nicht erkannt	1x	—	—	—
Gesamt inhaltliche Fehler	1	0	1	0

Timeouts

	deepseek-r1:7b	qwen3:8b	deepseek-r1:14b	qwen3:14b
Timeouts (>300s)	1x (371s)	0	0	0

Qualitätsbewertung der Inhalte

Sprache

Aspekt	deepseek-r1:7b	qwen3:8b	deepseek-r1:14b	qwen3:14b
Durchgehend Deutsch	Nein (Encoding-Artefakte, Kauderwelsch)	Ja	Meist (gelegentlich Englisch)	Ja
Grammatik	Häufig fehlerhaft	Gut	Gut	Sehr gut
Kohärenz	Schwach	Stark	Stark	Sehr stark

Persönlichkeitstreue

Wie gut werden die Eingabe-Persönlichkeitsmerkmale in den Output übernommen?

Merkmal	deepseek-r1:7b	qwen3:8b	deepseek-r1:14b	qwen3:14b
"28 Jahre"	Alter korrekt	Alter korrekt	Alter korrekt	Alter korrekt
"Softwareentwickler"	Ja	Ja	Ja	Ja (konkret: Backend-Entwicklung)
"sportlich"	Teilweise	Ja	Ja	Ja (Laufen, Mountainbiken, Klettern)
"liebt gutes Essen"	Teilweise	Ja	Ja	Ja (exotische Gerichte, Food-Festivals)
"introvertiert"	Ignoriert (erfindet Tochter, Partner)	Gut umgesetzt	Gut umgesetzt	Sehr gut (Angst vor Teamdruck, Konfliktvermeidung)
"trockener Humor"	Erwähnt, aber nicht stimmig	Natürlich eingebaut	Natürlich eingebaut	"humorvoll in technischen Diskussionen"

Realismus der Tagespläne

Aspekt	deepseek-r1:7b	qwen3:8b	deepseek-r1:14b	qwen3:14b
Arbeitszeiten	"16:45-24:00 Arbeit"	(JSON scheitert)	8h mit Pausen	8h mit Pausen + konkrete Aufgaben
Schlafenszeiten	OK	(JSON scheitert)	7-9h realistisch	7-8h realistisch
Aktivitäten	"Morgencode", "Liebesabend mit Futtern"	—	"Jogging", "Science-Fiction-Roman lesen"	"Backend-Entwicklung", "Klettern mit Freunden"
Mahlzeiten	Teilweise	—	Frühstück, Mittag, Abend	Frühstück, Mittag, Kochabend
Pendeln	Fehlt	—	15 min Heimweg	1h Fahrrad (hin + zurück)
Detailgrad	5-6 Blöcke	—	14-20 Blöcke	13 (Wochentag) / 10 (Wochenende)

Empfehlung

Für Planning-Agents (PlanningAiService, SchedulePlanning, ChatPlanAnalysis)

qwen3:14b — klarer Gewinner:

- Einziges Modell mit **21/21 (100%)** — kein einziger JSON-Fehler, kein inhaltlicher Fehler
- Durchgehend auf Deutsch, kein Sprachwechsel ins Englische
- Bestes Reasoning: prüft Kollisionsfreiheit, erklärt Entscheidungen mit Bezug zu Bedürfnissen
- Schnellste Gesamtzeit unter den 14b-Modellen (15:03 vs. 16:39 min)
- Lückenlose Stundenpläne mit kreativen, persönlichkeitsgetreuen Details

deepseek-r1:14b — gute Alternative (90%):

- 19/21 bestanden, nur 1 JSON-Fehler und 1 Lücke im Stundenplan
- Etwas schneller bei komplexen Prompts (~70s vs. ~92s)
- Wechselt gelegentlich ins Englische

Für Execution-/Enrichment-Agents (ExecutionAiService, EnrichmentAiService, BackgroundEnrichment, ScheduleEnrichment)

qwen3:8b — bewährt und zuverlässig:

- 11/12 Testläufe bestanden (über alle vier Testläufe)
- Gute kreative Textgenerierung (Blogartikel, Erzähltexte)
- Schnellere Antwortzeiten als 14b-Modelle
- Geringerer VRAM-Verbrauch

Nicht empfohlen

deepseek-r1:7b für Structured Output:

- Häufig kaputtes JSON (3 Parsing-Fehler + 1 Timeout)
- Inhaltlich unzuverlässig (erfindet Familienmitglieder, Kauderwelsch)
- Kein Vorteil gegenüber **qwen3:8b** bei gleichem Ressourcenverbrauch

qwen3:8b als Planning-Modell:

- Nur 76% Erfolgsrate — häufige JSON-Parsing-Fehler bei komplexen Strukturen
- Als Execution-Modell exzellent, aber für Structured Output mit verschachtelten Listen überfordert

Optimale Konfiguration

```
vbuddy:
  ai:
    planning:
      model-name: qwen3:14b          # Zuverlässigstes JSON + bestes Reasoning + Deutsch
    execution:
      model-name: qwen3:8b          # Kreatives Schreiben
    chat:
      model-name: llama3.1:8b       # Natürlicher Dialog (nicht getestet)
    schedule:
      model-name: qwen3:14b         # Komplexe Zeitstrukturen, lückenlos
```